

Relatório – Classificação do Estado Operacional de Sistemas Espaciais com Redes Neurais Artificiais

Integrantes:

- Felipe Hui Hattori – RM565169
- Kauany Ribeiro de Moura – RM564576
- Lucas Kenzo Nishiwaki – RM561325

1. Estratégia Adotada

O objetivo deste trabalho foi desenvolver e avaliar modelos de redes neurais artificiais utilizando Keras para classificar o estado operacional de sistemas espaciais simulados a partir de dados de sensores e telemetria. O processo iniciou-se com o carregamento das bases de treinamento e teste, seguido da separação entre variáveis de entrada e variável alvo. Posteriormente, os dados foram padronizados utilizando StandardScaler para garantir que todas as variáveis apresentassem escalas semelhantes durante o treinamento.

As classes da variável alvo foram convertidas para o formato categórico (One-Hot Encoding), permitindo a utilização da função de perda `categorical_crossentropy`.

2. Modelos Testados

Foram desenvolvidos três modelos distintos de redes neurais artificiais:

Modelo 1 – Rede Simples

- 1 camada oculta com 32 neurônios;
- Função de ativação ReLU;
- Camada de saída Softmax;
- Otimizador Adam.

Modelo 2 – Rede Profunda

- 3 camadas ocultas com 64, 32 e 16 neurônios;
- Função de ativação ReLU;
- Camada de saída Softmax;
- Otimizador Adam.

Modelo 3 – Rede com Regularização

- 2 camadas ocultas com 64 e 32 neurônios;
- Camadas Dropout de 30%;
- Função de ativação ReLU;
- Camada de saída Softmax;
- Otimizador Adam.

3. Experimentações Realizadas

Foram realizadas comparações entre diferentes arquiteturas de redes neurais com o objetivo de analisar o impacto da complexidade do modelo e da utilização de técnicas de regularização.

As experimentações envolveram:

- Diferentes quantidades de camadas ocultas;
- Diferentes quantidades de neurônios;
- Utilização de Dropout;
- Comparação do comportamento da loss e da accuracy durante o treinamento;
- Avaliação final utilizando o conjunto de testes.

4. Principais Resultados

Os resultados obtidos demonstraram elevado desempenho em todos os modelos avaliados.

Modelo	Accuracy	Loss
Modelo 1	99,20%	0,0259
Modelo 2	98,52%	0,0368
Modelo 3	98,89%	0,0240

O Modelo 1 apresentou a maior accuracy, enquanto o Modelo 3 apresentou o menor valor de loss.

5. Análise Crítica dos Resultados

A comparação entre os modelos mostrou que o aumento da profundidade da rede nem sempre resulta em melhor desempenho. Embora o Modelo 2 possuísse maior capacidade de aprendizado devido ao maior número de camadas, seu desempenho foi inferior ao do Modelo 1.

Também foram observados indícios de overfitting no Modelo 2, uma vez que modelos mais complexos tendem a memorizar características específicas dos dados de treinamento.

O Modelo 3 utilizou a técnica de Dropout, que reduziu o risco de overfitting ao desativar aleatoriamente parte dos neurônios durante o treinamento. Como consequência, apresentou melhor capacidade de generalização e o menor valor de loss entre os modelos avaliados.

Em relação à estabilidade do treinamento, todos os modelos apresentaram comportamento adequado, com redução gradual da loss e aumento da accuracy ao longo das épocas. Entretanto, o Modelo 3 demonstrou curvas mais consistentes durante a validação.

6. Conclusões da Equipe

Os resultados obtidos demonstraram que redes neurais artificiais são altamente eficazes para a classificação de estados operacionais em sistemas espaciais simulados.

O Modelo 1 apresentou o melhor desempenho geral em termos de accuracy, alcançando aproximadamente 99,20% de acerto. Já o Modelo 3 destacou-se pela melhor capacidade de generalização e menor valor de loss, graças à utilização da técnica de Dropout.

Conclui-se que a escolha da arquitetura da rede deve buscar equilíbrio entre desempenho e complexidade. Além disso, técnicas de regularização são importantes para evitar overfitting e melhorar a robustez dos modelos em situações reais.